

LEAF: 面向低资源语言翻译的分层评估与保证框架

发现并缓解 ReAct 检索系统中的查询漂移问题

黄咏郁 (2026110008)

大模型驱动的软件开发 · 清华大学 · 2026年6月

摘要

全球 7,000 种语言中超过 40% 面临濒危，主流大语言模型（GPT-4、GLM-4）对低资源语言的零样本翻译 BLEU 得分为 0。本文提出 **LEAF (Layered Evaluation and Assurance Framework)**，一个面向低资源语言翻译品质保证的 Multi-Agent 框架，以排湾语 (Paiwan, ISO 639-3: pag) 为验证语言。

我们在 ReAct 架构中发现了一种稳定的失败模式——**查询漂移 (Query Drift)**：LLM 在迭代推理中擅自改写检索查询，漂移率高达 35%，其中 71% 直接导致翻译错误。LEAF 通过四层品质保证 (CoreVocab / RAG / Grammar / Verify) 和 Multi-Agent 编排，将漂移率从 35% 降至 0%，翻译准确率从 65% 提升至 **95%**。消融实验证明，30pp 提升全部来自架构设计本身。

实验在排湾语 (5,923 条语料) 和阿美语 (6,413 条语料) 上完成双语言交叉验证。**关键词**：低资源语言翻译、Multi-Agent、ReAct、查询漂移、消融实验

1 引言

1.1 问题背景

低资源语言面临双重困境：数字语料匮乏导致大语言模型无法直接处理，而语言濒危的紧迫性要求技术方案"少数数据、快部署"。主流 LLM 的零样本翻译 BLEU 为 0.0（表 1）。

表 1：零样本基线实验

模型	方向	题数	BLEU	完全匹配率
GLM-4-Flash	中文→排湾语	40	0.000	0.0%
GLM-4-Plus	中文→排湾语	40	0.000	2.5%
ICL 5-shot	中文→排湾语	40	0.000	0.0%
ICL 10-shot	中文→排湾语	40	0.000	0.0%
ICL 20-shot	中文→排湾语	40	0.000	7.5%

即使 20-shot ICL，BLEU 仍为 0——排湾语在 LLM 预训练数据中几乎不存在。

1.2 RAG 的希望与脆弱性

仅 242 条语料，关键词 RAG 即可将完全匹配率提升至 90%（表 2）。

表 2：RAG 基线实验

方法	语料量	BLEU	完全匹配率
关键词 RAG	242 条	0.452	90.0%
向量 RAG	242 条	0.416	85.0%
混合 RAG	4,844 条	0.873	77.5%

然而，RAG 在低资源场景中极其脆弱——语料太少，容不下模糊匹配。当 LLM 在 ReAct 循环中改写查询时（如"月亮"→"月亮的族语怎么说"），精确匹配立刻失败。

1.3 贡献

1. 量化查询漂移：ReAct 单 Agent 中漂移率 35%，71% 直接导致错误
2. 提出 LEAF 框架：四层品质保证 + Multi-Agent 编排，架构级约束查询透传
3. 完整消融验证：8 配置 Truth Table + 双语言交叉验证

2 相关工作

低资源语言 NLP。传统统计机器翻译需大量平行语料（Koehn et al., 2007），零样本跨语言迁移（Conneau et al., 2020）依赖类型学相似性。

RAG 在翻译中的应用。检索增强生成（Lewis et al., 2020）补充 LLM 知识盲区，但现有工作未关注查询被改写导致的失败。

Multi-Agent 系统。AutoGen（Wu et al., 2023）等关注任务分解，较少研究编排对检索品质的影响。

ReAct 范式。Yao et al. (2023) 让 LLM 在推理中调用工具，正是此"自由推理"引发了查询漂移。


3 方法

3.1 系统架构

LEAF 包含 3 个核心 Agent：

- **Coordinator Agent（协调智能体）**：系统协调者，负责 ReAct 流程控制与工具路由。核心职责是**保护用户原始 Query**——无论后续进行多少轮推理或工具调用，原始问题都会被完整保留，不被 LLM 自动改写。
- **Knowledge Agent（知识智能体）**：封装所有语言知识来源，包括 Exact Match、RAG Search 和 CoreVocab 词汇库，负责找到候选翻译结果。
- **Quality Agent（品质智能体）**：通过反向翻译验证检查候选答案是否正确。验证失败则触发下一轮检索与修正。

简言之：Knowledge Agent 负责「找得到」，Quality Agent 负责「找对了」，Coordinator Agent 负责确保整个流程不会因 Query Drift 而偏离用户意图。



3.2 四层品质保证

层级	名称	功能	机制
L1	CoreVocab	词汇约束	词典 + 精确匹配，输出约束在已知词汇空间
L2	RAG	检索增强	关键词 + 向量 (FAISS) 混合检索
L3	Grammar	语法注入	音韵规则 + 缀词分析
L4	Verify	反向验证	反向翻译检查是否回到原文

3.3 查询漂移定义

ReAct 单 Agent 中 LLM 会改写检索查询。漂移类型：扩展型（月亮→月亮的族语怎么说）、改写型（孩子→小孩子的怎么说）、语义漂移型（朋友→朋友说什么语言）。

3.4 架构级约束

核心不是 prompt engineering，而是**架构设计**：① 查询透传（代码层面确保原封不动）② 结构化工具调用（schema 约束参数）③ 失败回退（切换检索策略而非改写查询）。

4 实验

4.1 实验设置


排湾语（5,923 条）+ 阿美语（6,413 条）双语言验证。基座模型 GLM-4-Flash。测试集 20 题中文→排湾语。指标：BLEU、Exact Match、漂移率。

4.2 实验 A：8 配置消融

表 3：8 配置消融

#	配置	准确率	差值
1	LLM Direct	0%	—
2	RAG Only	80%	+80pp
3	Single Agent（无 ReAct）	80%	0pp
4	SA + ReAct（free）	65%	-15pp
5	SA + Constrained ReAct	~80%	+15pp
6	Multi-Agent w/ SA prompt	90%	+25pp
7	Multi-Agent w/o Quality	95%	+5pp
8	Multi-Agent（完整）	95%	0pp

关键：#3→#4 唯一下降步骤——ReAct 引入反而降 15pp（查询漂移）。#4→#6 的 +25pp 为 Coordinator 架构约束的恢复。



4.3 实验 B：查询漂移量化

表 4：漂移率对比

配置	漂移率	漂移→错误率
SA 无 ReAct	0%	N/A
SA + ReAct（free）	35%	71%
SA + Constrained	30%	—
Multi-Agent + ReAct	0%	N/A

Constrained Prompt 仍 30% 漂移。证明 prompt engineering 无法根治，架构级约束必要。

4.4 实验 C：组件归因

表 5：组件消融

移除组件	准确率	Δ
—（完整）	95%	—
Quality Agent	95%	0pp
Pre-routing	95%	0pp
System Prompt	90%	-5pp
Architecture ($\rightarrow$ SA+ReAct)	65%	-30pp

归因：架构控制 +25pp，prompt +5pp，其余 0pp。

4.5 实验 D：四层消融（双语言）

实验组	排湾语	Δ	阿美语	Δ
Control	79.2%	—	73.5%	—
- CoreVocab	45.8%	-33pp	38.8%	-35pp
- Grammar	75.0%	-4pp	73.5%	0pp
- Verify	83.3%	+4pp	73.5%	0pp

L1 CoreVocab 为绝对支柱（-33pp）。双语言验证一致，Control 仅差 5.7pp。

4.6 实验 E：Query Drift 恢复

6 个刻意构造的漂移失败案例：Prompt-only 0/6，LEAF 6/6。

5 讨论

查询漂移是 LLM 内在行为，Constrained Prompt 仅 35%→30%。LEAF 通过职责分离、结构化传递、失败恢复三项架构设计解决。双语言验证中 CoreVocab 贡献一致（-33pp vs -35pp），捕捉到低资源翻译通用瓶颈。局限：测试集 20 题规模较小；GLM-4-Flash 上 L4 效果不稳定；仅验证单向翻译。

6 结论

1. 查询漂移是 ReAct 固有缺陷：35% 漂移率，71% 致错，prompt engineering 无法根治
2. 架构级约束是方案：Multi-Agent 编排降至 0% 漂移，65%→95%（+30pp），全部来自架构设计
3. 框架可迁移：排湾语+阿美语双语言验证一致
- 核心洞察：架构设计优于 prompt engineering。

参考文献

[1] Conneau et al. (2020). Unsupervised cross-lingual representation learning at scale. *ACL*.
[2] Koehn et al. (2007). Moses: Open source toolkit for SMT. *ACL*.
[3] Lewis et al. (2020). Retrieval-augmented generation. *NeurIPS*.

[4] Wu et al. (2023). AutoGen. *arXiv:2308.08155*.

[5] Yao et al. (2023). ReAct. *ICLR*.

附录 A：Query Drift 失败案例

#	原始	漂移后	类型	答案	SA+ReAct	MA
q06	月亮	月亮的族语怎么说	扩展	qiljas	✗	✓
q12	父亲	爸爸的排湾语	改写	ama	✗	✓
q13	孩子	小孩子的怎么说	改写	aljak	✗	✓
q16	人	人的族语是什么	扩展	caucau	✗	✓
q17	朋友	朋友说什么语言	漂移	kabang	✗	✓
q19	名字	名字怎么念	改写	ngadan	✗	✓

附录 B：双语言消融数据

配置	排湾语	阿美语
四层全开	79.2% (39.6/50)	73.5% (36.8/50)
– CoreVocab	45.8% (–33.4pp)	38.8% (–34.7pp)
– Grammar	75.0% (–4.2pp)	73.5% (0pp)
– Verify	83.3% (+4.1pp)	73.5% (0pp)

附录 C：代码仓库 — <https://github.com/yoanahappy2/LEAF>